

Clasificación Supervisada de Estrellas Variables con Bosques Aleatorios

Juan David Aparicio Gutiérrez

Universidad de los Andes — Astrofísica Observacional con Machine Learning

Resumen

Se presenta la clasificación supervisada de 6 366 estrellas variables del relevamiento OGLE-IV en cuatro categorías: binarias, variables de período largo (LPV), pulsantes y otras. Partiendo únicamente de series de tiempo fotométricas en las bandas I y V , se construyeron y evaluaron nueve features estadísticos mediante histogramas por clase. Tras la exploración se retuvieron cuatro: el color calculado con el estimador de biweight location $(V - I)_{BW}$, el logaritmo del período obtenido con Lomb-Scargle a partir de la curva de luz en banda I , la asimetría y la amplitud fotométrica. Un clasificador de bosque aleatorio con estos cuatro features alcanzó una exactitud global del 91.2 %, con el mejor desempeño para las LPV ($F1 = 0.962$).

1. Introducción

El estudio de estrellas variables ocupa un lugar central en la astrofísica moderna: su variabilidad fotométrica revela propiedades físicas como radio, temperatura efectiva, período de pulsación y geometría orbital. Con el advenimiento de grandes relevamientos fotométricos, la cantidad de curvas de luz disponibles crece más rápido que la capacidad de clasificarlas manualmente, lo que motiva el uso de técnicas de aprendizaje automático supervisado.

En este trabajo se aplica un clasificador de bosque aleatorio para distinguir cuatro tipos de estrellas variables a partir de features estadísticos derivados *exclusivamente* de las curvas de luz en las bandas I y V , sin utilizar ningún parámetro previo del catálogo como feature.

1.1. Los datos

Los datos provienen del Experimento de Lente Gravitacional Óptica en su cuarta fase (OGLE-IV; [Udalski et al. 2015](#)), uno de los relevamientos fotométricos de largo plazo más exhaustivos

del hemisferio sur. OGLE-IV opera con el telescopio de 1.3 m de Varsovia en el Observatorio de Las Campanas (Chile) y ha monitoreado millones de estrellas durante más de una década con cadencias de muestreo que van de días a semanas.

Para este trabajo se utilizaron curvas de luz de los campos LMC562 y LMC563, correspondientes a regiones de la Nube Mayor de Magallanes (LMC) observadas en las bandas fotométricas I (infrarrojo cercano, $\lambda_{\text{ef}} \approx 806 \text{ nm}$) y V (visual, $\lambda_{\text{ef}} \approx 551 \text{ nm}$). Cada estrella cuenta con una serie de tiempo de magnitud aparente en función del tiempo heliocéntrico juliano (HJD), con su incertidumbre fotométrica asociada.

Todos los features del modelo se extraen directamente de las curvas de luz; el catálogo se utiliza únicamente para las etiquetas de clase. El único criterio de exclusión es la no disponibilidad simultánea de curva de luz en ambas bandas, más tres clases de muy escasa representación estadística (T2CEP, ACER y ACEP). La **muestra de trabajo** queda compuesta por **6 366 estrellas**.

1.2. Tipos de estrellas variables

Las estrellas variables se clasifican de acuerdo con el mecanismo físico que origina su variabilidad (Karttunen et al. 2016; Samus' et al. 2017). En este trabajo se trabaja con cuatro categorías:

Binarias (BINARY). Un sistema binario está formado por dos estrellas que orbitan en torno a su centro de masa común (Karttunen et al. 2016). La variabilidad fotométrica puede producirse por dos mecanismos: en las *binarias en eclipse* (ECL), uno de los componentes pasa periódicamente frente al otro bloqueando parcialmente su luz; en las *elipsoidales* (ELL), la deformación de marea genera variaciones de flujo sin eclipse (Pawlak et al. 2016; Soszyński et al. 2016). Sus períodos van desde pocas horas hasta decenas de días. La muestra incluye 1 434 binarias.

Variables de período largo (LPV). Son gigantes rojas en estados avanzados de evolución estelar cuya variabilidad se origina en pulsaciones radiales de gran amplitud. Incluyen las estrellas tipo Mira, semirregulares y otras variables lentas (Mattei 1997; Soszyński et al. 2009). Sus períodos típicamente superan los 100 días y sus amplitudes son de las mayores observadas. Es la clase más numerosa de la muestra: 2 607 estrellas.

Pulsantes (PULSATING). Agrupa tres subtipos bien estudiados: las *RR Lyrae* (RRLYR), con períodos entre 0.2 y 1 día (Soszynski et al. 2009); las *cefeidas clásicas* (DCEP), con períodos de 1 a 100 días y la famosa relación período-luminosidad de Leavitt (Soszynski et al. 2008); y las *Delta Scuti* (DSCT), variables pulsantes de baja amplitud y rápida variación (Pietrukowicz et al.

2013). En los tres casos el mecanismo de ionización del helio sostiene la pulsación. La muestra incluye 913 pulsantes.

Otras (OTHER). Categoría heterogénea que agrupa objetos cuya variabilidad no corresponde a ninguna de las clases anteriores (p. ej., Be, T Tauri u otras variables de naturaleza incierta). Son 1 412 estrellas.

1.3. Bosques aleatorios

Un bosque aleatorio (*Random Forest*) es un clasificador de ensamble propuesto por Breiman (2001) que combina múltiples árboles de decisión entrenados de forma independiente. Cada árbol se construye sobre una muestra con reemplazo (*bootstrap*) del conjunto de entrenamiento, introduciendo variabilidad entre árboles. En cada nodo de división solo se considera un subconjunto aleatorio de $\lfloor \sqrt{p} \rfloor$ features candidatos (donde p es el total), descorrelacionando los árboles. La predicción final se obtiene por votación mayoritaria.

La combinación de *bagging* y selección aleatoria de features reduce la varianza sin aumentar el sesgo, haciéndolo robusto frente al sobreajuste.

Una propiedad adicional valiosa es la **importancia de Gini** (también denominada *Mean Decrease in Impurity*, MDI). Para definirla, se parte de la impureza de Gini (Breiman et al. 1984) de un nodo t con n_t muestras distribuidas entre K clases:

$$G(t) = 1 - \sum_{k=1}^K \hat{p}_{tk}^2, \quad (1.1)$$

donde $\hat{p}_{tk}$ es la fracción de muestras de clase k en el nodo. Un nodo perfectamente puro tiene $G = 0$; un nodo con mezcla uniforme alcanza el máximo $G = 1 - 1/K$. Cuando se divide el nodo t en dos hijos t_L y t_R , la reducción de impureza asociada a esa división es

$$\Delta G(t) = G(t) - \frac{n_{t_L}}{n_t} G(t_L) - \frac{n_{t_R}}{n_t} G(t_R). \quad (1.2)$$

La importancia del feature j se obtiene acumulando estas reducciones, ponderadas por la proporción de muestras que pasan por cada nodo, a lo largo de todos los árboles del bosque (Breiman 2001):

$$\text{MDI}(j) = \frac{1}{|\mathcal{T}|} \sum_{T \in \mathcal{T}} \sum_{\substack{t \in T \\ v(t)=j}} \frac{n_t}{n} \Delta G(t), \quad (1.3)$$

donde $\mathcal{T}$ es el conjunto de árboles, $v(t)$ es el feature empleado en la división del nodo t y n es el tamaño del conjunto de entrenamiento. Las puntuaciones resultantes se normalizan para que

sumen la unidad. Un feature que separa consistentemente las clases en muchos nodos acumula una puntuación alta independientemente de la profundidad en que ocurra la división.

Se utilizó la implementación de `scikit-learn` (Pedregosa et al. 2011) con 500 árboles y semilla aleatoria fija para reproducibilidad.¹

2. Objetivos

1. Construir un conjunto de features estadísticos derivados exclusivamente de series de tiempo fotométricas en las bandas I y V para la caracterización de curvas de luz de estrellas variables.
2. Evaluar el poder discriminante de cada feature mediante histogramas superpuestos por clase y seleccionar un subconjunto representativo para la clasificación.
3. Entrenar y evaluar un clasificador de bosque aleatorio para la clasificación supervisada de cuatro tipos de estrellas variables a partir de los features seleccionados.
4. Analizar la importancia relativa de los features seleccionados e identificar los más informativos para la tarea de clasificación.

3. Metodología

3.1. Exploración y definición de features

Se evaluó un conjunto de nueve features candidatos. Para cada uno se generó un histograma superpuesto por clase, comparando visualmente las distribuciones de las cuatro categorías (Fig. 3.1). A continuación se define cada feature explorado.

¹El código completo de este trabajo está disponible en github.com/juand4g/AstroML_202610.




Figura 3.1: Distribución de los cuatro features retenidos para cada clase. *Arriba izq.:* color biweight $(V - I)_{BW}$. *Arriba der.:* logaritmo del período calculado con Lomb-Scargle. *Abajo izq.:* asimetría de la curva de luz en banda I . *Abajo der.:* amplitud fotométrica en banda I . Las LPV se distinguen por su color más rojo y sus amplitudes y períodos mayores.

Amplitud (A). Diferencia entre la magnitud más tenue y la más brillante en la curva de luz en banda I :

$$A = m_{\text{máx}} - m_{\text{mín}}. \quad (3.1)$$

Cuantifica el rango de variación fotométrica. Las LPV muestran amplitudes típicamente superiores a 0.5 mag.

Asimetría (*skewness*, γ_1). Tercer momento estadístico estandarizado de la distribución de magnitudes:

$$\gamma_1 = \frac{E[(m - \bar{m})^3]}{\sigma^3}. \quad (3.2)$$

Una distribución simétrica tiene $\gamma_1 = 0$. Las pulsantes y binarias muestran asimetrías características relacionadas con la forma de sus curvas de luz.

Curtosis (γ_2). Cuarto momento estandarizado (exceso):

$$\gamma_2 = \frac{E[(m - \bar{m})^4]}{\sigma^4} - 3. \quad (3.3)$$

Aunque explorado, no fue incluido en el modelo final por su aportación marginal y su relación tan estrecha con la asimetría.

Magnitud media. Promedio de la magnitud en banda I . Descartada como feature; véase la Sección 4.

Estadístico KPSS. Estadístico de la prueba de estacionariedad de Kwiatkowski-Phillips-Schmidt-Shin (Kwiatkowski et al. 1992) sobre la serie temporal de magnitudes. Los histogramas no mostraron separación apreciable entre clases y fue descartado.

Tasa de extremos locales. Proporción de puntos de la curva de luz que son extremos locales, estimada como el número de cambios de signo en la diferencia discreta $\Delta m_i = m_{i+1} - m_i$ dividido por la longitud de la serie. La distribución resultó similar para todas las clases y fue descartada.

Color biweight $(V - I)_{BW}$. Diferencia entre el estimador de biweight location de las magnitudes en banda V y en banda I :

$$(V - I)_{BW} = T_{BW}(V) - T_{BW}(I). \quad (3.4)$$

El biweight location (Beers et al. 1990) es un estimador robusto de tendencia central. Dado un conjunto de magnitudes $\{m_i\}$ con mediana M y desviación absoluta de la mediana S , se definen pesos normalizados $u_i = (m_i - M)/(cS)$. El estimador resulta:

$$T_{BW} = M + \frac{\sum_{|u_i| < 1} (m_i - M)(1 - u_i^2)^2}{\sum_{|u_i| < 1} (1 - u_i^2)^2}, \quad (3.5)$$

con constante de ajuste $c = 9$. Las mediciones más alejadas que cS de la mediana reciben peso nulo, lo que lo hace resistente a valores atípicos como puntos contaminados por rayos cósmicos o artefactos de reducción fotométrica. El color refleja la temperatura efectiva de la estrella y no depende de la distancia.

$\ln P_{LS}$. Logaritmo natural del período dominante calculado de la curva de luz en banda I mediante el periodograma de Lomb-Scargle (Lomb 1976; Scargle 1982). El periodograma ajusta, para cada frecuencia de prueba ν_k , una senoide a los datos no uniformemente muestreados

por mínimos cuadrados y computa una potencia espectral normalizada; la frecuencia de máxima potencia define el período adoptado $P_{LS} = 1/\nu_{k^*}$. Se evaluaron 20 000 frecuencias en el rango 0.1–150 días.

3.2. Selección final y entrenamiento

Tras la exploración visual se conservaron cuatro features: color biweight $(V - I)_{BW}$, $\ln P_{LS}$, asimetría y amplitud. El conjunto de datos se dividió en 80 % para entrenamiento y 20 % para evaluación con estratificación por clase. Se entrenó un bosque aleatorio con 500 árboles.

4. Problemas presentados y soluciones aplicadas

El desafío del *feature engineering*. Uno de los aspectos más críticos del trabajo fue decidir qué información extraer de las curvas de luz. En una primera exploración, el catálogo OGLE reporta el período fotométrico para la mayoría de las estrellas, lo que podría simplificar la tarea si se usara directamente. Sin embargo, en un escenario real donde solo se dispone de la serie temporal de magnitud versus tiempo, el período debe calcularse desde cero mediante periodogramas como el de Lomb-Scargle (Lomb 1976; Scargle 1982) o el de mínima entropía (Cincotta et al. 1995), cuya fiabilidad depende de la calidad y densidad de muestreo. La elección de qué estadísticos adicionales extraer para capturar las particularidades de cada tipo de variabilidad requiere comprensión del dominio y múltiples iteraciones de exploración y descarte.

La recuperación del período con Lomb-Scargle, evaluada comparando P_{LS} con el período de catálogo para las estrellas que lo tienen disponible, alcanzó el 63.7 % global (con tolerancia ± 5 %, incluyendo mitad y doble período). El desglose por clase revela una asimetría marcada: Binarias (92.2 %), Pulsantes (87.2 %), Otras (88.8 %) y LPV (27.0 %). La baja recuperación en las LPV ocurre porque sus períodos suelen superar los 150 días (el límite superior del rango de búsqueda), de modo que Lomb-Scargle identifica armónicos u otras señales espurias. Pese a ello, las LPV son la clase mejor clasificada del modelo ($F1 = 0.962$), lo que demuestra que el color biweight y la amplitud son suficientemente discriminantes incluso cuando el período calculado es incorrecto.

La magnitud como feature. La magnitud media en banda I resulta tentadora porque los diagramas color-magnitud muestran separación entre clases (las LPV son sistemáticamente más brillantes en I por ser gigantes rojas de gran luminosidad). No obstante, la magnitud aparente

depende simultáneamente de la luminosidad intrínseca, la distancia y la extinción interestelar, factores independientes del tipo de variabilidad. Usar la magnitud como feature introduciría sesgos espurios: dos estrellas del mismo tipo, situadas a distancias diferentes, se verían fotométricamente distintas. El color $(V - I)_{BW}$, al ser una diferencia entre magnitudes en dos bandas, es mayormente un observable intrínseco y no depende de la distancia, por lo que constituye un sustituto robusto.

5. Resultados

El modelo de cuatro features alcanzó una **exactitud global del 91.2 %** sobre el conjunto de evaluación (1 273 estrellas). La Tabla 5.1 resume las métricas por clase; la Figura 5.1 muestra la importancia de cada feature según el criterio de Gini, y la Figura 5.2 presenta la matriz de confusión.

Tabla 5.1: Métricas de clasificación por clase del modelo final con cuatro features. El soporte indica el número de estrellas en el conjunto de evaluación.

Clase	Precisión	Exhaustividad	F1	Soporte
Binarias	0.898	0.829	0.862	287
LPV	0.943	0.983	0.962	521
Otras	0.849	0.837	0.843	282
Pulsantes	0.936	0.956	0.946	183
Prom. pond.	0.911	0.912	0.911	1273




Figura 5.1: Importancia de cada variable según el criterio de Gini, promediada sobre los 500 árboles. El color biweight $(V-I)_{BW}$ es la variable más discriminante (Gini = 0.446), seguida de la asimetría (0.230), la amplitud (0.172) y el logaritmo del período LS (0.153).




Figura 5.2: Matriz de confusión del modelo final sobre el conjunto de evaluación (1 273 estrellas). Cada celda indica el número de estrellas predichas como la clase de la columna siendo realmente de la clase de la fila.

El color biweight $(V - I)_{BW}$ es el feature más informativo (importancia Gini = 0.446), seguido de la asimetría (0.230), la amplitud (0.172) y el logaritmo del período LS (0.153). La mayor importancia del color respecto al período refleja un resultado notable: incluso cuando el período calculado es impreciso (como ocurre para las LPV), las propiedades de la distribución de magnitudes bastan para discriminar las clases.

Las LPV y las Pulsantes obtienen las métricas más altas. Las Binarias y las Otras muestran el mayor solapamiento mutuo: las binarias elipsoidales pueden presentar curvas de luz relativamente suaves que se confunden con las de la clase Otras, mientras que esta última agrupa objetos heterogéneos sin un patrón fotométrico único.

6. Conclusiones

1. Un bosque aleatorio con cuatro features derivados íntegramente de las curvas de luz — color biweight $(V - I)_{BW}$, $\ln P_{LS}$, asimetría y amplitud— clasifica estrellas variables del catálogo OGLE-IV con una exactitud global del 91.2 %, demostrando que la estructura fotométrica de las series de tiempo codifica información suficiente para distinguir los principales tipos de variabilidad.
2. El color biweight $(V - I)_{BW}$ resultó ser el feature más importante (Gini = 0.446), indicando que la temperatura efectiva de la estrella es el discriminante primario entre clases. Las LPV, como gigantes rojas muy frías, presentan colores marcadamente más rojos que el resto.
3. La selección de features es el paso más crítico del proceso. La exploración sistemática permitió descartar la magnitud media (dependiente de la distancia), el estadístico KPSS y la tasa de extremos locales, cuyas distribuciones no separaron las clases de forma adecuada.
4. Las LPV obtienen el mejor desempeño (F1 = 0.962) pese a que Lomb-Scargle solo recupera su período correctamente en el 27 % de los casos, lo que evidencia que el color y la amplitud son suficientes para identificarlas. La clase Otras, de naturaleza heterogénea, presenta el mayor índice de confusión con las Binarias.

Referencias

- Beers, T. C., Flynn, K., & Gebhardt, K. 1990, *The Astronomical Journal*, 100, 32
- Breiman, L. 2001, *Machine Learning*, 45, 5
- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. 1984, *Classification and Regression Trees* (Monterey, CA: Wadsworth & Brooks/Cole)
- Cincotta, P. M., Mendez, M., & Nunez, J. A. 1995, *ApJ*, 449, 231
- Karttunen, H., Kröger, P., Oja, H., Poutanen, M., & Donner, K. J. 2016, *Fundamental Astronomy*, sixth edition edn. (Springer Nature)
- Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. 1992, *Journal of Econometrics*, 54, 159
- Lomb, N. R. 1976, *Ap&SS*, 39, 447
- Mattei, J. A. 1997, *Journal of the American Association of Variable Star Observers*, 25, 57
- Pawlak, M., Soszyński, I., Udalski, A., et al. 2016, *Acta Astron.*, 66, 421
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. 2011, *Journal of Machine Learning Research*, 12, 2825
- Pietrukowicz, P., Dziembowski, W. A., Mroz, P., et al. 2013, *Acta Astronomica*, 63, 379
- Samus', N. N., Kazarovets, E. V., Durlevich, O. V., Kireeva, N. N., & Pastukhova, E. N. 2017, *Astronomy Reports*, 61, 80
- Scargle, J. D. 1982, *ApJ*, 263, 835
- Soszyński, I., Pawlak, M., Pietrukowicz, P., et al. 2016, *Acta Astron.*, 66, 405
- Soszynski, I., Poleski, R., Udalski, A., et al. 2008, *Acta Astronomica*, 58, 163
- Soszynski, I., Udalski, A., Szymanski, M. K., et al. 2009, *Acta Astronomica*, 59, 1
- Soszyński, I., Udalski, A., Szymański, M. K., et al. 2009, *Acta Astronomica*, 59, 239
- Udalski, A., Szymański, M. K., & Szymański, G. 2015, *Acta Astronomica*, 65, 1